analise

April 21, 2026

1 Análise Exploratória e Modelagem Preditiva

Problema e Coleta de Dados

O objetivo deste projeto é desenvolver um modelo de Machine Learning capaz de prever a ocorrência de doença cardiovascular com base em características clínicas e demográficas dos pacientes.

O problema é de classificação binária:

- 0 → Sem doença cardiovascular
- 1 → Com doença cardiovascular

Este tipo de problema possui grande relevância na área da saúde, pois permite a identificação precoce de pacientes com risco elevado, auxiliando na tomada de decisão médica.

1.1 Carregamento e Limpeza dos Dados

Inicialmente, o conjunto de dados foi carregado e passou por um processo de limpeza para garantir maior qualidade das informações.

Foram realizadas as seguintes etapas:

- Remoção da coluna `id`, por não possuir valor preditivo
- Filtragem de valores inconsistentes (outliers extremos)
- Padronização dos dados para análise

A remoção de outliers é essencial para evitar distorções nos modelos e garantir maior robustez nas previsões.

1.2 Engenharia de Atributos (Feature Engineering)

Foram criadas novas variáveis com o objetivo de melhorar a capacidade preditiva do modelo.

Dentre as principais transformações, destacam-se:

- Conversão da idade de dias para anos (`age_years`)
- Cálculo do índice de massa corporal (`bmi`)
- Criação de métricas de pressão arterial:
  - `pulse_pressure` (diferença entre pressão sistólica e diastólica)
  - `mean_pressure` (média das pressões)
- Criação de variáveis indicadoras de risco:
  - pressão alta

  - colesterol elevado
  - glicose elevada
- Criação de um score de risco (`risk_score`)
- Interação entre idade e pressão (`pressure_age`)

Essas variáveis simulam indicadores clínicos reais e ajudam o modelo a capturar padrões mais complexos.

1.3 Análise Exploratória dos Dados (EDA)

1.3.1 Mapa de Correlação

O mapa de correlação permite identificar relações entre as variáveis do conjunto de dados.

Observa-se que variáveis relacionadas à pressão arterial, idade e BMI apresentam maior correlação com a variável alvo (doença cardiovascular).

Essa análise é importante para entender quais atributos possuem maior potencial preditivo.

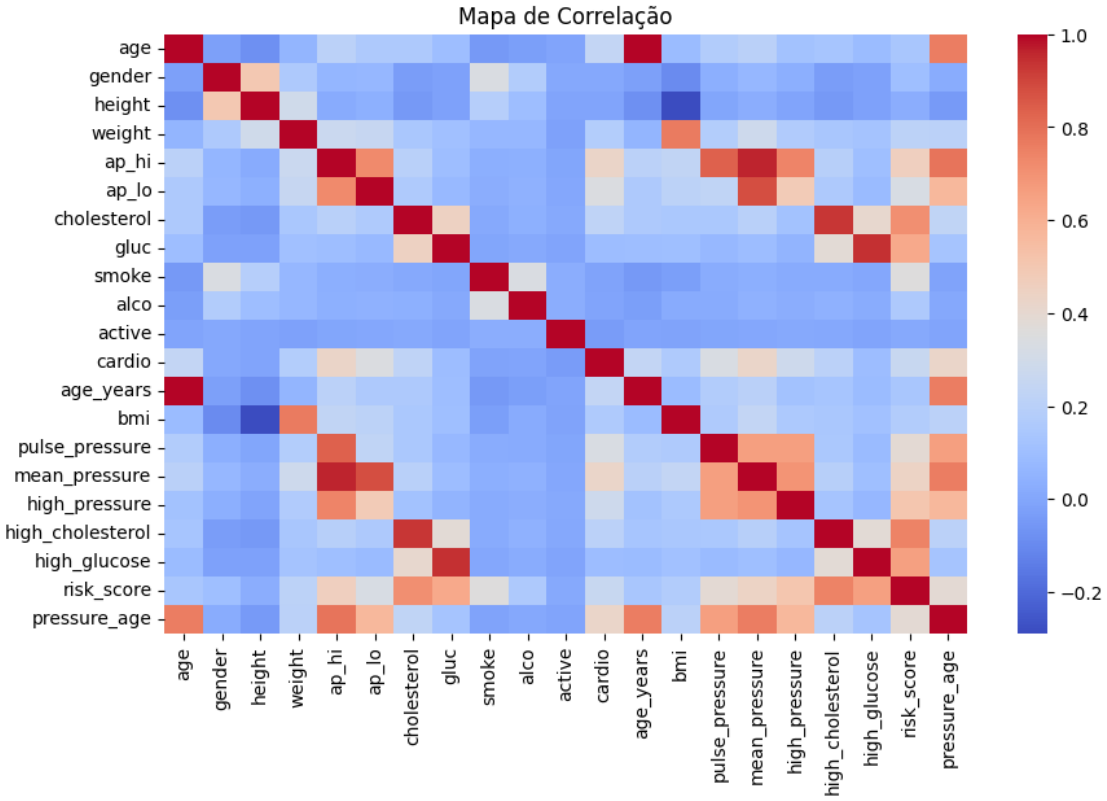

1.3.2 Distribuição das Variáveis

Foram utilizados boxplots para analisar a distribuição de variáveis importantes em relação à presença de doença cardiovascular.

Nos gráficos, é possível observar:

- A **linha central** representa a mediana
- A **caixa** representa a faixa entre o primeiro e terceiro quartil (50% dos dados)
- As **linhas verticais** representam a dispersão dos dados
- Os **pontos fora da caixa (outliers)** representam valores extremos

1.3.3 Principais insights:

- Pacientes com doença cardiovascular tendem a apresentar:
  - maior idade
  - maior pressão arterial
  - maior BMI

Essas diferenças indicam que as variáveis possuem capacidade de discriminar entre as classes.

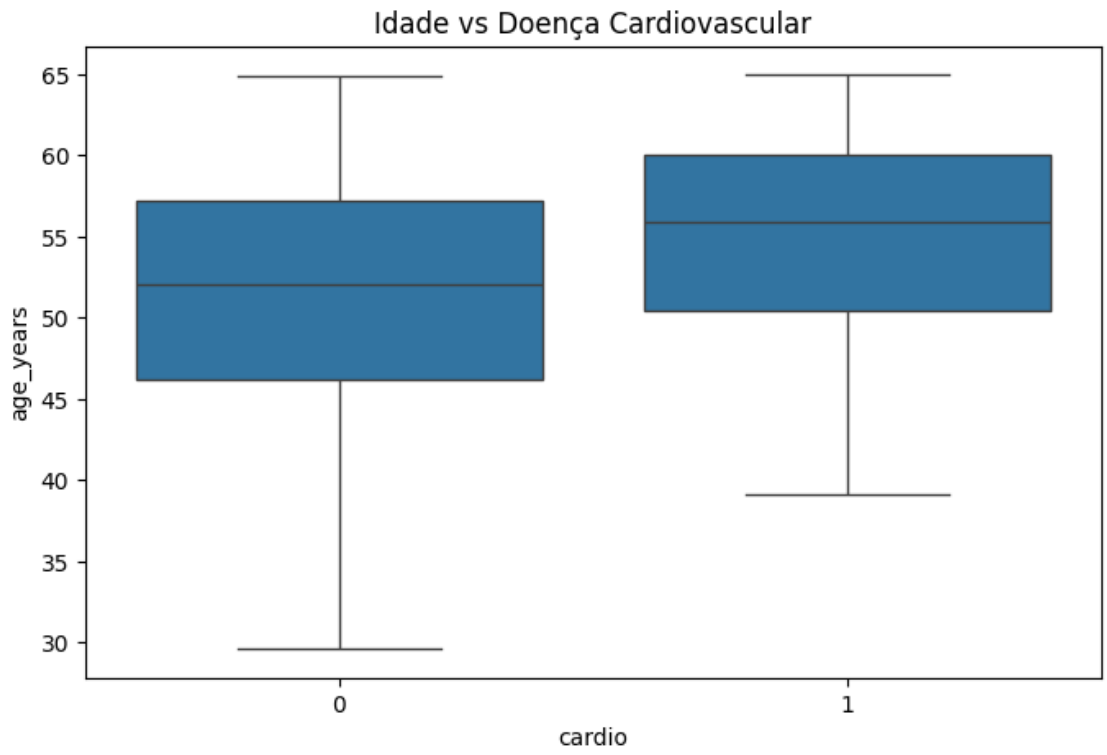

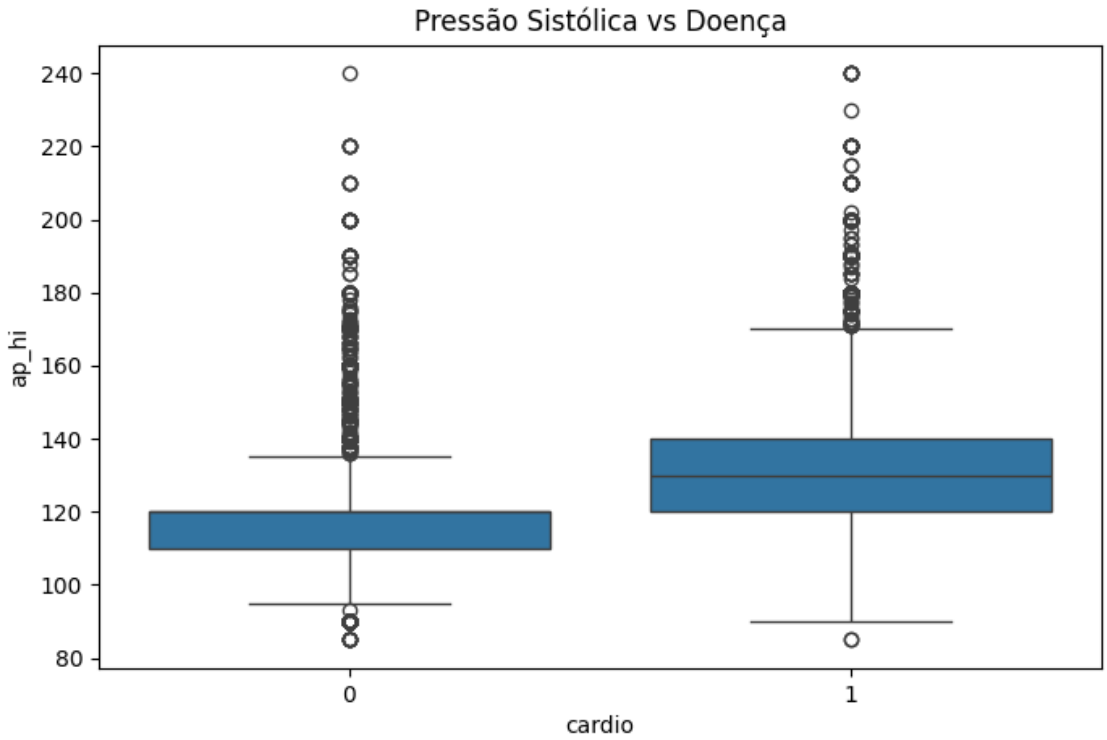
Pressão Sistólica vs Doença
ap_hi
240
220
200
180
160
140
120
100
80
0
1
cardio

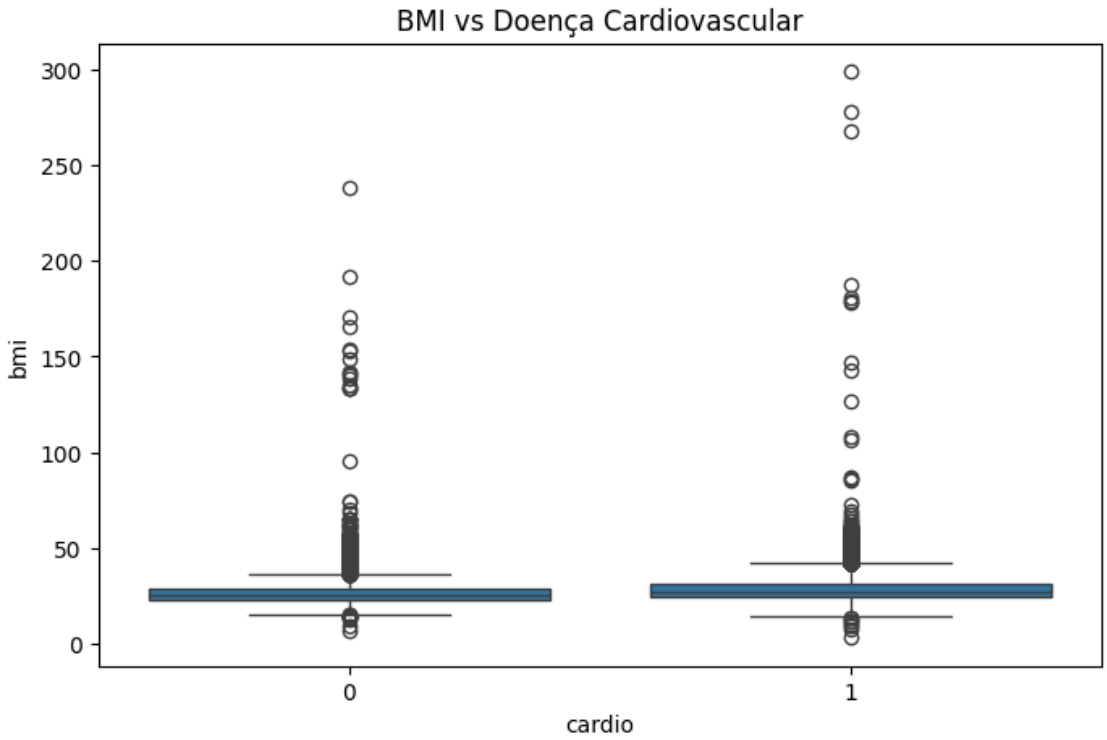
BMI vs Doença Cardiovascular
bmi
300
250
200
150
100
50
0
0
1
cardio

1.4 Treinamento e Comparação de Modelos

Foram avaliados diferentes algoritmos de Machine Learning:

- Regressão Logística
- Random Forest
- XGBoost

A comparação foi realizada com base nas seguintes métricas:

- Accuracy (Acurácia)
- Precision (Precisão)
- Recall (Sensibilidade)
- F1-score

Embora a acurácia seja uma métrica importante, o foco principal foi o **Recall**, devido à natureza do problema.

1.5 Resultados da Comparação

Os modelos apresentaram desempenhos próximos em termos de acurácia, porém diferenças importantes em relação ao recall.

Em problemas médicos, é fundamental minimizar falsos negativos, ou seja, evitar classificar pacientes doentes como saudáveis.

Por esse motivo, o modelo escolhido foi aquele com melhor equilíbrio entre recall e precisão.

	Modelo	Accuracy	Recall	Precision	F1-score
2	Random Forest	0.711879	0.692092	0.716463	0.704067
1	Logistic Regression	0.728725	0.691651	0.742844	0.716334
0	XGBoost	0.725735	0.684583	0.741704	0.711999

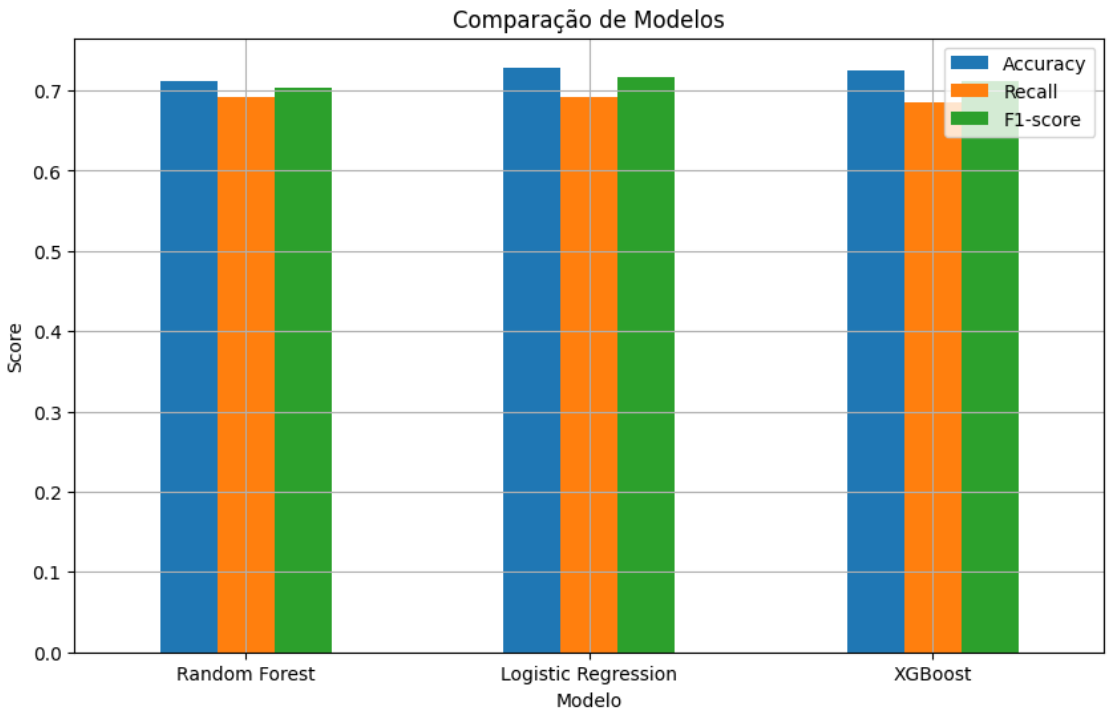


```
Melhor modelo: Random Forest
```

1.6 Seleção do Modelo Final

Embora o Random Forest tenha apresentado o maior recall inicial, o modelo XGBoost foi selecionado como modelo final devido à sua maior capacidade de generalização e melhor desempenho após ajuste de hiperparâmetros.

Além disso, o XGBoost é conhecido por sua eficiência em capturar relações não lineares e interações complexas entre variáveis, tornando-o mais robusto para problemas reais.

Dessa forma, a escolha do modelo final não se baseou apenas em uma métrica isolada, mas no equilíbrio entre desempenho, interpretabilidade e capacidade de generalização.

1.7 Ajuste do Threshold (Limiar de Decisão)

Por padrão, modelos de classificação utilizam 0.5 como limite para decisão.

Neste trabalho, foi realizado um ajuste do threshold com o objetivo de priorizar a detecção de pacientes doentes.

O modelo (train_model) foi configurado para atingir um **recall mínimo de 80%**, reduzindo a quantidade de falsos negativos.

Essa abordagem é fundamental em contextos médicos, onde a falha em identificar um paciente doente pode ter consequências graves.

1.8 Curva ROC

A curva ROC avalia a capacidade do modelo de separar as classes.

Quanto mais próxima a curva estiver do canto superior esquerdo, melhor o desempenho do modelo.

O valor de AUC (Área sob a curva) resume essa capacidade: - Quanto mais próximo de 1, melhor

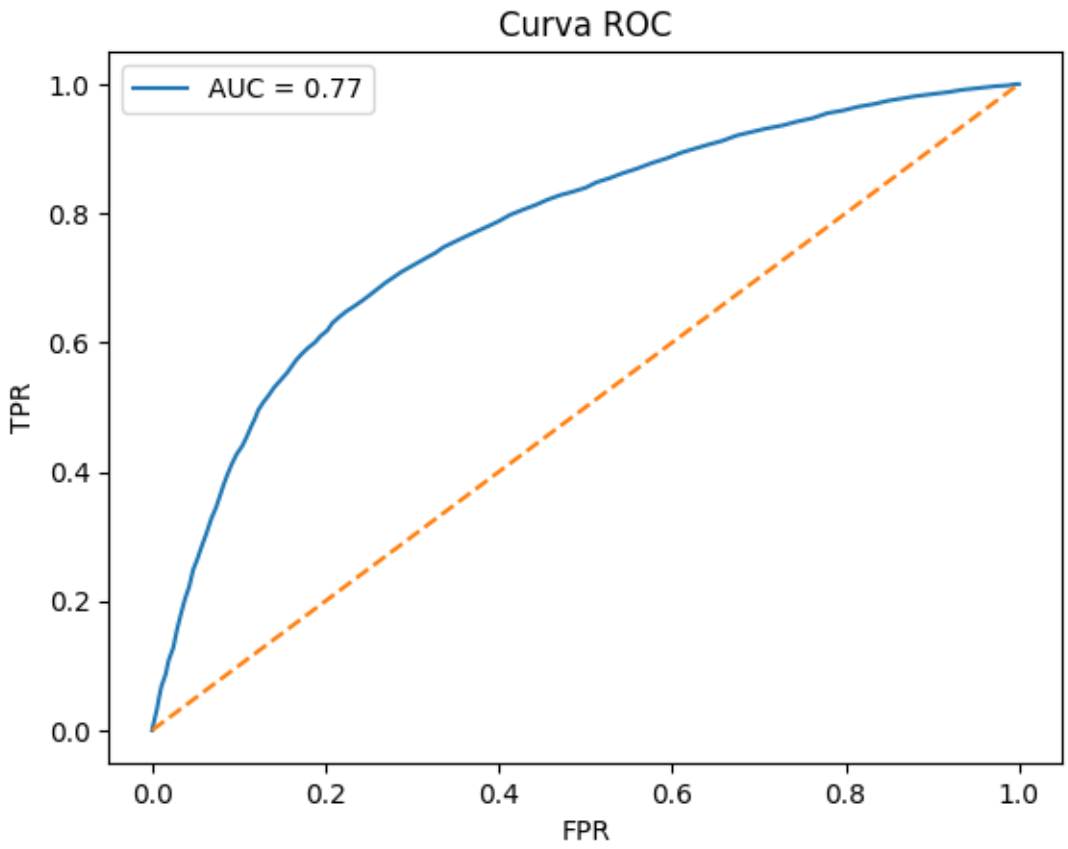

1.9 Curva Precision-Recall

A curva Precision-Recall é mais adequada para cenários com possível desbalanceamento de classes.

Ela mostra o trade-off entre: - Precisão (quantos positivos estão corretos) - Recall (quantos positivos foram detectados)

Essa análise reforça a escolha do modelo com foco em recall.

1.10 Calibration Curve

A curva de calibração avalia se as probabilidades previstas pelo modelo correspondem à realidade.

Um modelo bem calibrado apresenta valores próximos da linha diagonal.

Isso é importante em aplicações onde a probabilidade em si é relevante, como análise de risco.

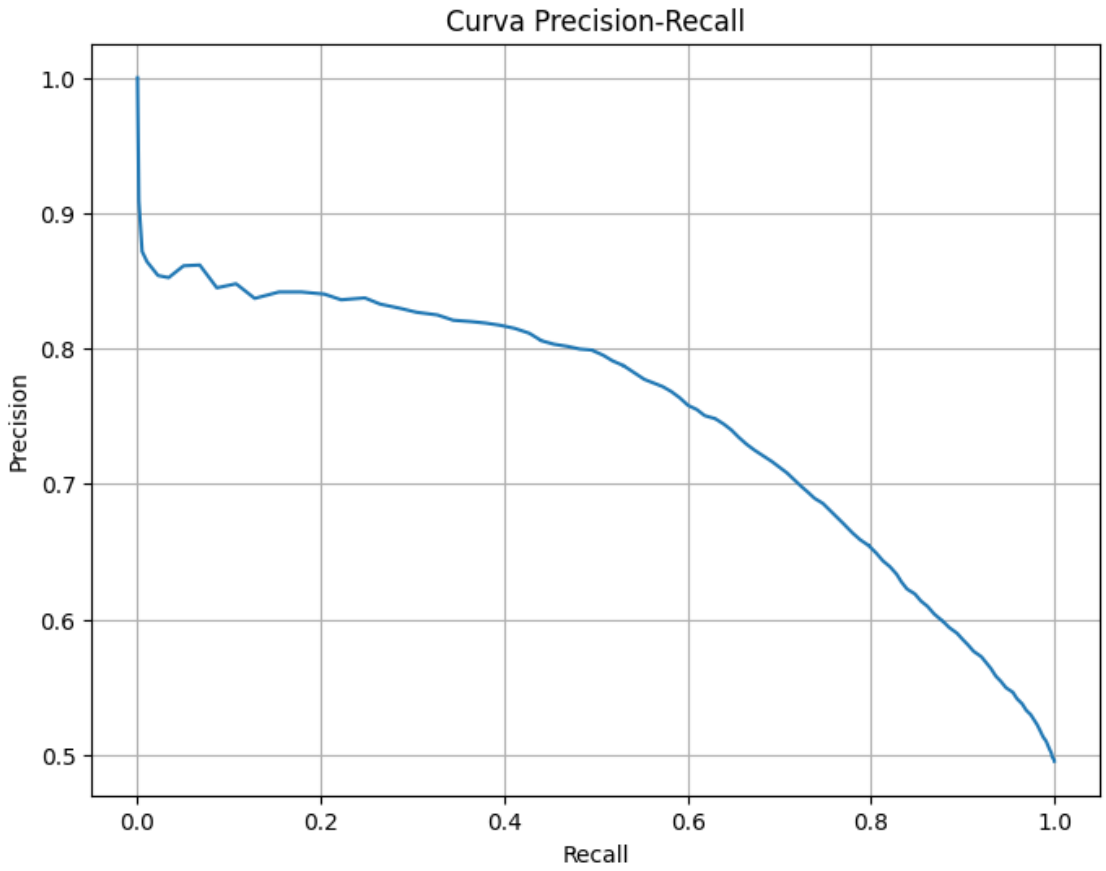
Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.0
0.2
0.4
0.6
0.8
1.0

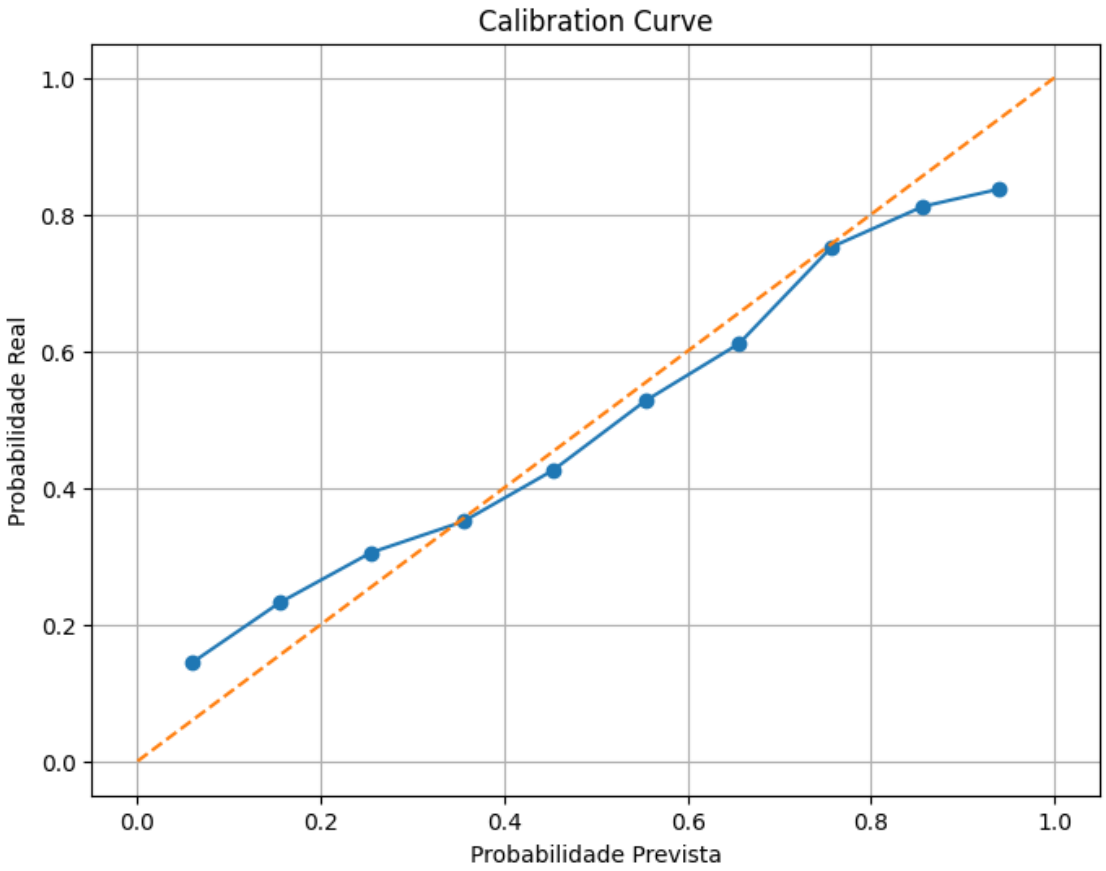

1.11 Importância das Variáveis

A análise de importância das variáveis permite identificar quais atributos mais influenciam o modelo.

Observa-se que variáveis relacionadas à pressão arterial, idade e BMI possuem maior impacto na previsão.

Isso está alinhado com o conhecimento médico sobre fatores de risco cardiovascular.

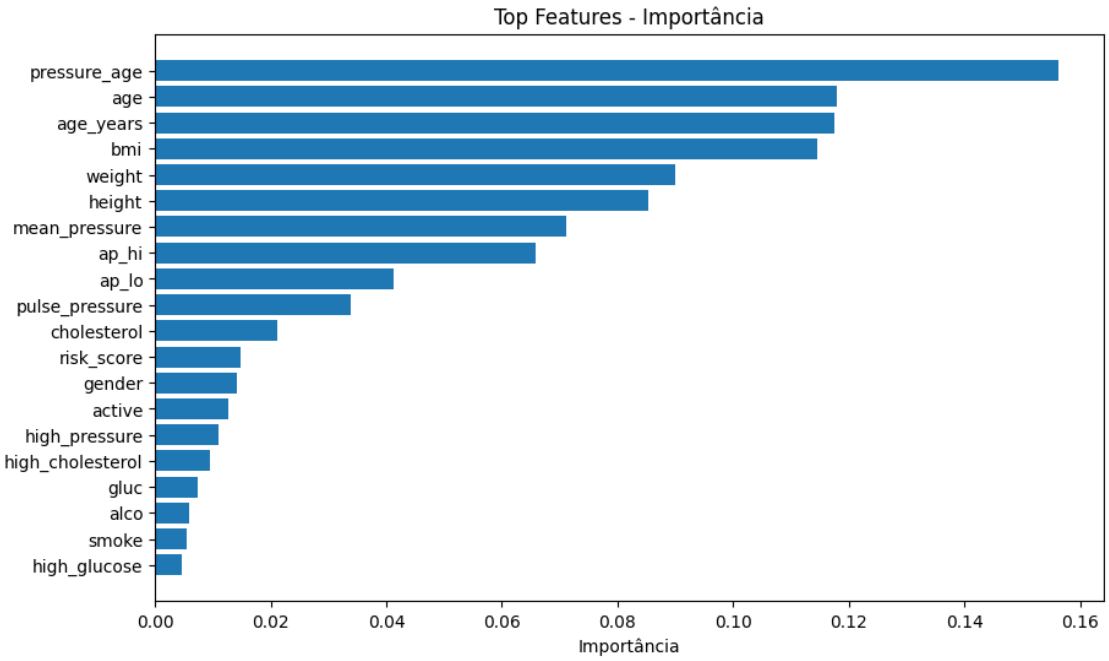

1.12 Interpretabilidade do Modelo (SHAP)

O SHAP (SHapley Additive exPlanations) foi utilizado para interpretar as decisões do modelo.

Ele permite entender: - Quais variáveis influenciam cada previsão - Como cada variável contribui positiva ou negativamente

Essa análise aumenta a transparência do modelo, o que é essencial em aplicações na área da saúde.

1.13 2. Conclusão

Este trabalho teve como objetivo desenvolver um modelo de Machine Learning capaz de prever a ocorrência de doenças cardiovasculares a partir de variáveis clínicas e demográficas. Ao longo do projeto, foram aplicadas etapas fundamentais de um pipeline de ciência de dados, incluindo análise exploratória, engenharia de atributos, treinamento de modelos, avaliação de desempenho e interpretabilidade.

A análise exploratória dos dados permitiu identificar padrões relevantes entre as variáveis e a presença de doença cardiovascular. Observou-se que fatores como idade, índice de massa corporal (BMI) e pressão arterial apresentam forte relação com o risco da doença, o que está alinhado com o conhecimento médico existente. Esses achados reforçam a qualidade dos dados e a relevância das variáveis utilizadas no modelo.

Durante a etapa de modelagem, diferentes algoritmos foram avaliados, incluindo Regressão Logística, Random Forest e XGBoost. Embora os modelos tenham apresentado desempenhos próximos em termos de acurácia, a escolha do modelo final foi baseada em uma análise mais aprofundada das métricas, especialmente o recall, devido à natureza crítica do problema. Em aplicações médicas, é

fundamental minimizar falsos negativos, ou seja, evitar que pacientes doentes sejam classificados como saudáveis.

Apesar do Random Forest ter apresentado o maior recall inicial, o modelo XGBoost foi selecionado como modelo final por sua maior capacidade de generalização e melhor desempenho após ajustes de hiperparâmetros. Além disso, o XGBoost demonstrou maior eficiência na captura de relações não lineares e interações complexas entre variáveis, tornando-o mais robusto para cenários reais.

Outro ponto relevante deste trabalho foi o ajuste do threshold de decisão do modelo. Ao invés de utilizar o valor padrão de 0.5, o limiar foi ajustado com o objetivo de atingir um recall mínimo de 80%, priorizando a identificação de pacientes com risco elevado. Essa abordagem evidenciou o trade-off entre precisão e recall, demonstrando que, ao aumentar a capacidade de detecção, há um aumento nos falsos positivos, o que é aceitável dentro do contexto da saúde preventiva.

A avaliação do modelo por meio da curva ROC indicou um bom desempenho na separação das classes, com um valor de AUC satisfatório. A curva Precision-Recall reforçou a análise do trade-off entre métricas, enquanto a curva de calibração demonstrou que as probabilidades previstas pelo modelo estão bem alinhadas com a realidade, o que é essencial para aplicações baseadas em risco.

Além disso, a análise de importância das variáveis e a utilização do SHAP (SHapley Additive exPlanations) permitiram interpretar o comportamento do modelo, aumentando sua transparência. Observou-se que variáveis relacionadas à pressão arterial, idade e BMI possuem maior impacto nas previsões, corroborando novamente o conhecimento clínico e aumentando a confiabilidade do modelo.

Por fim, conclui-se que o modelo desenvolvido apresenta potencial para auxiliar na identificação precoce de pacientes com risco de doenças cardiovasculares, podendo servir como ferramenta de apoio à decisão médica. Como trabalhos futuros, sugere-se a utilização de bases de dados mais completas, inclusão de novas variáveis clínicas e validação do modelo em ambientes reais, visando aumentar ainda mais sua precisão e aplicabilidade prática.